¿Qué es el aprendizaje supervisado?

Introducción al curso · y sus diferencias con el aprendizaje no supervisado y por refuerzo

Datos con respuesta · Minimizar el riesgo empírico · Generalizar

Regresión · Clasificación · Agrupamiento · Q-learning

Tres formas de aprender de la experiencia

Supervisado

Datos: ejemplos con la respuesta correcta.

Retroalimentación: para cada ejemplo se conoce el resultado esperado.

Aprende a: predecir la respuesta para datos nuevos.

Ejemplo: diagnosticar un tumor a partir de imágenes ya diagnosticadas.

No supervisado

Datos: solo observaciones, sin respuesta.

Retroalimentación: ninguna.

Aprende a: descubrir estructura (grupos, patrones, factores).

Ejemplo: agrupar clientes por sus hábitos de compra.

Por refuerzo

Datos: los que genera el agente al actuar.

Retroalimentación: una recompensa, a veces tardía.

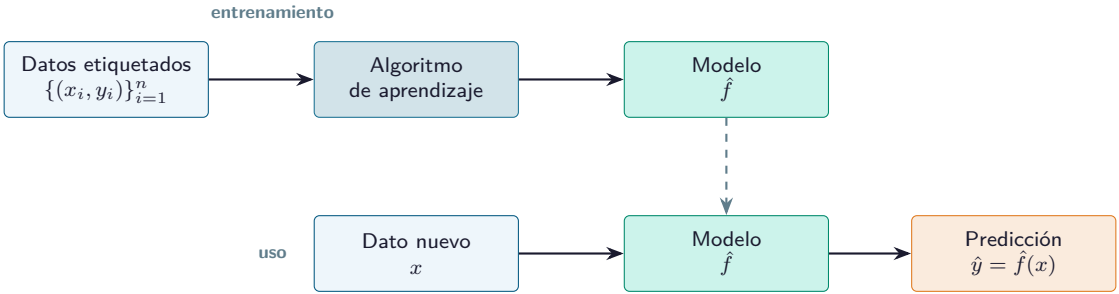
Aprende a: elegir acciones que maximicen la recompensa acumulada.

Ejemplo: un robot que aprende a caminar.

La diferencia clave es qué tipo de retroalimentación recibe el algoritmo

Este curso trata el **aprendizaje supervisado**: es el paradigma más usado en la práctica y el que mejor se puede evaluar.

Aprendizaje supervisado: aprender una función a partir de ejemplos



Ejemplos

Entrada x	**Respuesta** y
mediciones del núcleo de una célula	maligno o benigno
características de una vivienda	precio de venta
texto de un correo	spam o no spam

Lo esencial

El modelo no se juzga por lo que *ya vio*, sino por lo bien que responde a datos **nuevos**.

Formalización: minimizar el riesgo empírico

Datos y objetivo

Muestra $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{n}$ con $x_i \in \mathcal{X} \subseteq \mathbb{R}^p$ y $y_i \in \mathcal{Y}$, tomada de una distribución desconocida $P(X, Y)$.

Se busca $f : \mathcal{X} \to \mathcal{Y}$ tal que $f(x) \approx y$ en datos **nuevos**.

Pérdida y riesgo

$L(y, \hat{y})$ mide el costo de equivocarse. El **riesgo** es el error esperado:

$$R(f) = \mathbb{E}_{(X,Y)\sim P}\left[L\Big(Y, f(X)\Big)\right]$$

No se puede calcular, porque P es desconocida.

Riesgo empírico (ERM)

Se sustituye la esperanza por el promedio en la muestra y se busca en una familia $\mathcal{F}$ de modelos:

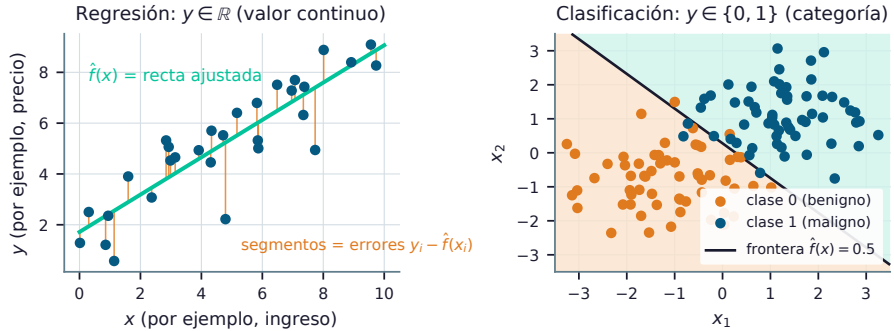
$$\hat{f} = \underset{f\in\mathcal{F}}{\arg\min}\ \frac{1}{n}\sum_{i=1}^{n} L\Big(y_i, f(x_i)\Big)\ \Big[+\lambda\,\Omega(f)\Big]$$

$\Omega(f)$ penaliza modelos demasiado complejos (regularización).

En el curso

Cada algoritmo (regresión lineal, árboles, SVM, redes, bosques…) es una elección distinta de $\mathcal{F}$, L y de cómo se resuelve el $\arg\min$.

Dos tipos de problemas supervisados: regresión y clasificación



Izquierda: datos simulados con su recta ajustada. Derecha: dos clases simuladas y la frontera de una regresión logística.

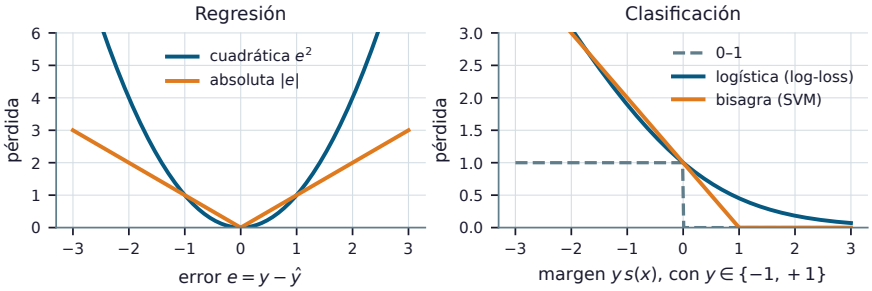
Regresión: $\mathcal{Y} = \mathbb{R}$

Se predice una cantidad: precio, temperatura, demanda.
Modelos: lineal, polinomial, SVR, árboles (sesiones 4 a 7).

Clasificación: $\mathcal{Y}$ finito

Se predice una categoría: spam, diagnóstico, fraude.
Modelos: logística, kNN, Bayes, SVM, redes (sesiones 8 a 12).

La pérdida define qué significa «equivocarse»



Derecha: $s(x)$ es la puntuación del modelo y $y \in \{-1, +1\}$; la pérdida logística se escaló para pasar por $(0, 1)$.

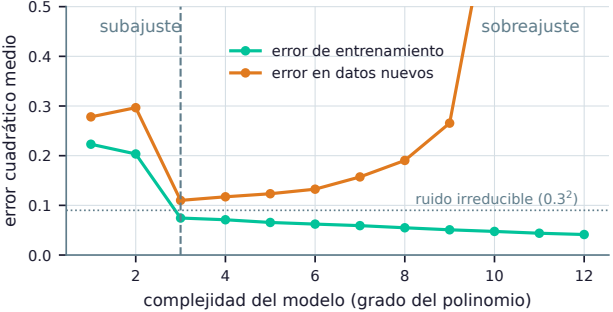
Regresión

Cuadrática: $L = (y - \hat{y})^2$ (castiga mucho los errores grandes).
Absoluta: $L = |y - \hat{y}|$ (más robusta a atípicos).

Clasificación

0–1: $L = \mathbf{1}[\hat{y} \neq y]$ (no se puede optimizar fácilmente).
Logística: $L = \log(1 + e^{-y\,s(x)})$. Bisagra: $L = \max(0,\, 1 - y\,s(x))$.

El objetivo real: generalizar, no memorizar



Datos simulados: $y = \sin(3x) + \varepsilon$, $\sigma = 0.3$, 25 puntos; mediana de 300 repeticiones.

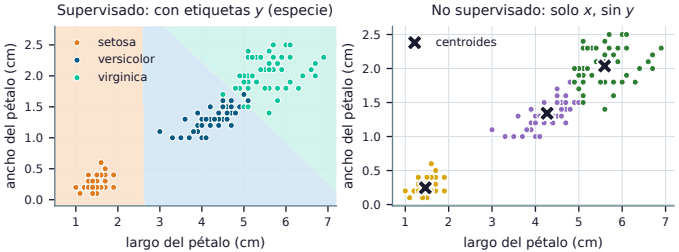
Qué se ve

- Grado 1 (recta): entrenamiento 0.22, nuevos 0.28. **Subajuste.**
- Grado 3: 0.07 y 0.11, cerca del ruido irreducible ($\sigma^2 = 0.09$).
- Grado 12: el error de entrenamiento sigue bajando (0.04), pero con datos nuevos se **dispara**.

Descomposición del error

$$\mathbb{E}\big[(y - \hat{f}(x))^2\big] = \underbrace{\text{sesgo}^2}_{\text{subajuste}} + \underbrace{\text{varianza}}_{\text{sobreajuste}} + \sigma^2$$

Aprendizaje no supervisado: los datos sin respuesta



Flores Iris (largo y ancho del pétalo). Izquierda: con la especie conocida, un clasificador acierta 96 % (en entrenamiento). Derecha: sin la especie, k-means ($k = 3$) forma grupos.

Agrupamiento (k-means)

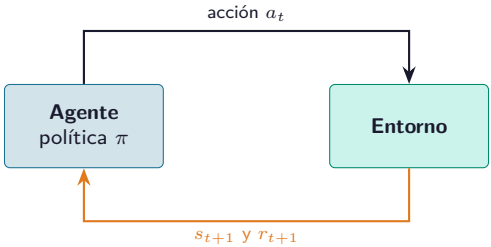
Solo hay $\{x_i\}$. Se buscan k grupos $C_1, \ldots, C_k$ con centros μ_j:

$$\min_{C,\mu} \sum_{j=1}^{k} \sum_{x_i \in C_j} \|x_i - \mu_j\|^2$$

Otras tareas

Reducción de dimensión (PCA): la dirección w de máxima varianza, $\max_{\|w\|=1} \mathrm{Var}(w^\top x)$. **Densidad y anomalías**: modelar $p(x)$. Los grupos coinciden con las especies (Rand ajustado 0.89), sin saber qué significan.

Aprendizaje por refuerzo: aprender actuando



Idea

No hay respuestas correctas, solo una **recompensa**. El agente prueba acciones, ve las consecuencias y mejora. Debe equilibrar *explorar* y *explotar* lo que ya sabe.

Retorno (recompensa acumulada)

$$G_t = \sum_{k=0}^{\infty} \gamma^k \, r_{t+k+1}, \qquad \gamma \in [0, 1)$$

Objetivo: la mejor política

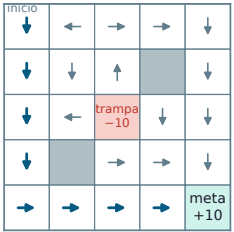
$$\pi^* = \arg\max_{\pi} \; \mathbb{E}_{\pi}\left[G_0\right]$$

Q-learning (actualización)

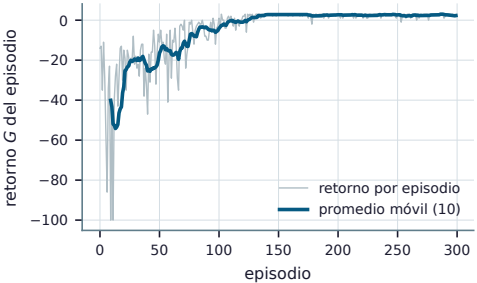
$$Q(s,a) \leftarrow Q(s,a) + \alpha \left[r + \gamma \max_{a'} Q(s',a') - Q(s,a) \right]$$

Ejemplo de refuerzo: Q-learning en una cuadrícula

Política aprendida $\pi(s)$ (flechas)



El agente mejora con la experiencia



Cuadrícula de 5×5: -1 por paso, $+10$ en la meta, -10 en la trampa; los cuadros grises son muros. 300 episodios con exploración ε que baja de 1 a 0.05.

Qué se ve

El retorno promedio de los primeros 20 episodios es -38.3 y el de los últimos 20 es 2.55: el agente aprende sin que nadie le diga la ruta.

La política aprendida

La ruta de 8 pasos (7 pasos de -1 y la meta, $+10$) da retorno 3, que es el máximo posible aquí. Rodea la trampa sin que se le haya prohibido.

Comparación de los tres paradigmas

	Supervisado	**No supervisado**	**Por refuerzo**
Datos	pares (x_i, y_i)	observaciones $\{x_i\}$	episodios (s_t, a_t, r_t)
Retroalimentación	respuesta correcta y_i	ninguna	recompensa r_t (a veces tardía)
Se aprende	una función $f : \mathcal{X} \to \mathcal{Y}$	estructura: grupos, factores, densidad	una política $\pi(a \mid s)$
Objetivo	$\min \ \frac{1}{n} \sum L(y_i, f(x_i))$	$\min J$ (k-means), $\max \mathrm{Var}$ (PCA)	$\max \ \mathbb{E}[G]$
Ejemplo	diagnóstico, precio	segmentar clientes	juegos, robótica
Evaluación	error en datos nuevos (prueba, validación cruzada)	coherencia y utilidad de los grupos (indirecta)	retorno acumulado

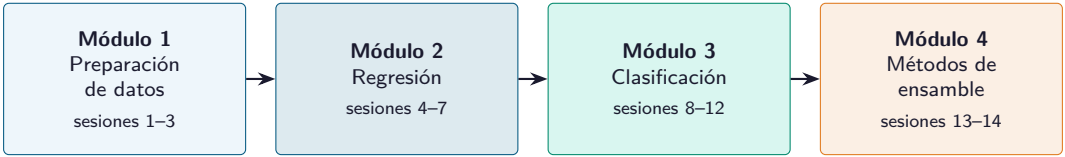
¿Qué paradigma es? (2 minutos, por parejas o en el chat)

#	Situación	Respuesta
1	Predecir el precio de una casa a partir de sus características.	
2	Agrupar clientes con hábitos de compra parecidos, sin categorías previas.	
3	Clasificar correos como spam usando correos ya etiquetados.	
4	Un robot aprende a caminar probando movimientos y recibiendo recompensa por avanzar.	
5	Reducir 30 mediciones a 2 variables para poder graficarlas (PCA).	
6	Detectar fraudes con transacciones ya marcadas como fraude o no fraude.	

¿Qué paradigma es? (2 minutos, por parejas o en el chat)

#	Situación	Respuesta
1	Predecir el precio de una casa a partir de sus características.	**Supervisado** (regresión)
2	Agrupar clientes con hábitos de compra parecidos, sin categorías previas.	**No supervisado** (agrupamiento)
3	Clasificar correos como spam usando correos ya etiquetados.	**Supervisado** (clasificación)
4	Un robot aprende a caminar probando movimientos y recibiendo recompensa por avanzar.	**Refuerzo**
5	Reducir 30 mediciones a 2 variables para poder graficarlas (PCA).	**No supervisado** (reducción de dimensión)
6	Detectar fraudes con transacciones ya marcadas como fraude o no fraude.	**Supervisado** (clasificación). Sin marcas sería detección de anomalías: no supervisado.

Dónde estamos: el curso es de aprendizaje supervisado



Flujo de trabajo de todo el curso

Explorar y preparar los datos → crear y seleccionar variables → ajustar el modelo → evaluar con rigor → combinar modelos.

Evaluación

Ejercicios de laboratorio (30 %), miniproyecto de regresión (35 %) y miniproyecto de clasificación (35 %). Cada sesión: concepto, fórmulas y una actividad en Python.

Ideas clave

Para llevarse

1. **Supervisado:** se aprende f a partir de pares (x_i, y_i) minimizando una pérdida; lo que importa es el error en datos **nuevos**.
2. **No supervisado:** sin respuesta y; se busca estructura en los datos.
3. **Por refuerzo:** se aprende una política a partir de recompensas, interactuando con un entorno.
4. **En este curso:** regresión y clasificación supervisadas, de los datos crudos a modelos validados.



¿Preguntas?

¡Bienvenidos al curso!