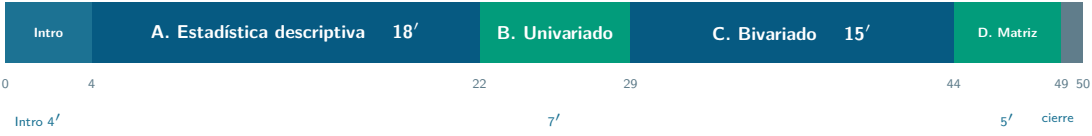
Preparación de datos y análisis exploratorio (EDA)

Unidad 1 · Estadística descriptiva, análisis univariado y bivariado, matrices de correlación

Media · Varianza · Asimetría · Curtosis · Boxplots e IQR · Correlación y heatmaps

California Housing · pandas · NumPy · Matplotlib

Plan de la unidad (≈50 min)



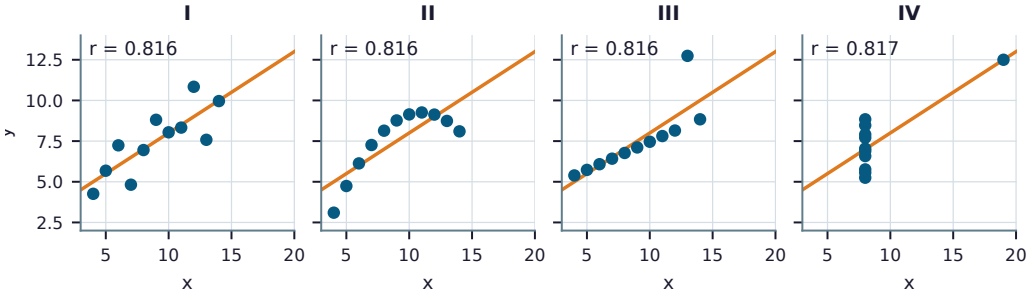
Qué veremos

- **A.** Media, varianza, asimetría y curtosis: qué miden y cómo se leen
- **B.** Histogramas, boxplots y la regla del IQR para detectar atípicos
- **C.** Dos variables a la vez: covarianza, correlación (Pearson y Spearman)
- **D.** Matriz de correlación y *heatmaps*
- Todo sobre un conjunto real: **California Housing**

Al terminar podrás

- Calcular e *interpretar* $\bar{x}$, s^2, γ_1 y κ
- Elegir entre histograma, boxplot o dispersión según la pregunta
- Marcar atípicos con $1.5 \cdot \mathrm{IQR}$ y **decidir** qué hacer con ellos
- Leer una matriz de correlación y reconocer sus límites

Antes de modelar: mirar los datos

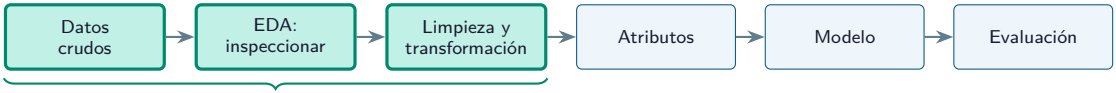


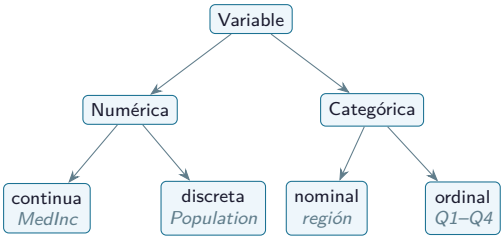
Los cuatro conjuntos (Anscombe, 1973) tienen **exactamente los mismos resúmenes**: $\bar{x} = 9$, $\bar{y} \approx 7.50$, $s_y^2 \approx 4.13$, $r \approx 0.816$ y la misma recta $\hat{y} = 3 + 0.5\,x$.

Moraleja

Los números *resumen*; las gráficas *revelan*. Hacemos las dos cosas.

Dónde encaja el EDA y con qué tipos de variable trabajamos

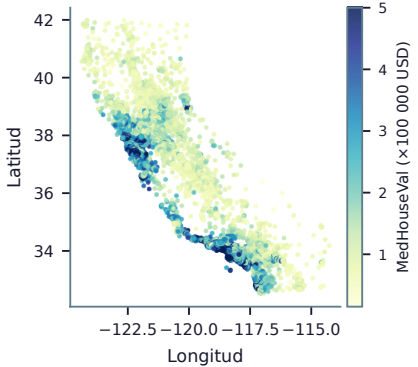




Tres preguntas del EDA

1. **¿Qué hay?** forma, centro, dispersión
2. **¿Qué está raro?** atípicos, topes, errores
3. **¿Qué se relaciona con qué?** pares y matrices

Nuestro conjunto de datos: California Housing



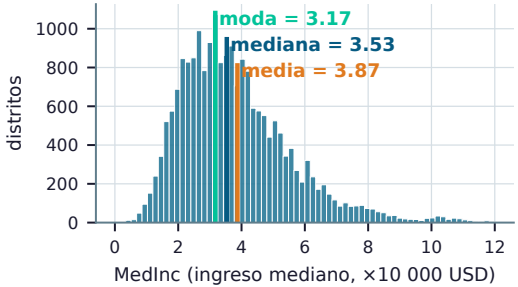
Cada punto es un distrito del censo de 1990; color = valor mediano de la vivienda.

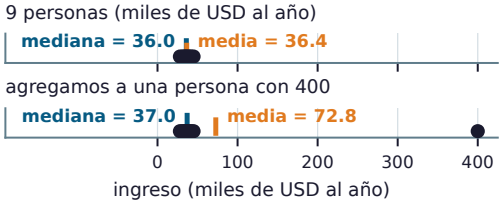
Variable	Qué describe (por distrito)
`MedInc`	ingreso mediano ($\times 10\,000$ USD)
`HouseAge`	edad mediana de las viviendas (años)
`AveRooms`	habitaciones promedio por hogar
`AveBedrms`	dormitorios promedio por hogar
`Population`	habitantes del distrito
`AveOccup`	ocupantes promedio por hogar
`Latitude`, `Longitude`	ubicación del distrito
`MedHouseVal`	**objetivo**: valor mediano ($\times 100\,000$ USD)

Ojo

$n = 20\,640$ **distritos**, no viviendas: cada fila ya es un resumen (mediana o promedio) de muchos hogares.

A1 · Medidas de centro: media, mediana y moda





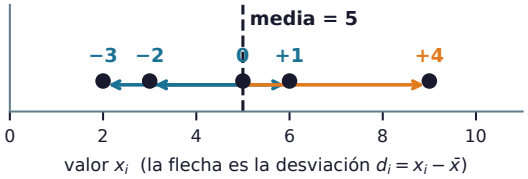
Definiciones

Media: $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$ (punto de equilibrio)
Mediana: dato central de los datos ordenados
Moda: valor más frecuente (el pico)

Robustez

- La **media** es el punto de equilibrio: un dato lejano la arrastra.
- La **mediana** casi no se mueve (36.0 → 37.0 vs. 36.4 → 72.8).
- En `MedInc`: moda < mediana < media ⇒ cola a la derecha.

A2 · Dispersión: la varianza como área de cuadrados



suma de áreas = 30 → varianza = 30/(n−1) = 7.5

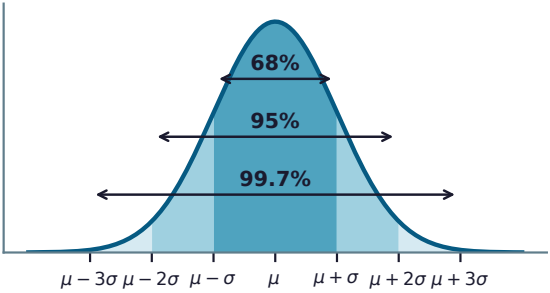
Varianza y desviación estándar

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2, \qquad s = \sqrt{s^2}$$

- Cada desviación $d_i = x_i - \bar{x}$ se eleva al cuadrado: **área** de un cuadrado de lado $|d_i|$.
- Promediamos áreas ⇒ varianza (unidades^2).
- La raíz s vuelve a las unidades originales: aquí $s = \sqrt{7.5} \approx 2.74$.

¿Por qué $n-1$? $\bar{x}$ sale de los mismos datos y queda más cerca de ellos que la media real: con n subestimaríamos la dispersión.

A3 · La desviación estándar como regla y el puntaje z



Puntaje z

$$z_i = \frac{x_i - \bar{x}}{s}$$

"¿A cuántas desviaciones estándar de la media está este dato?"

- **Si** la forma es de campana: 68 / 95 / 99.7 % dentro de $\pm 1s, \pm 2s, \pm 3s$.
- Sin suponer forma (Chebyshev): al menos $1 - 1/k^2$ dentro de $\pm ks$ (75 % con $k = 2$).
- `MedInc` real: 75.9 / 95.9 / 98.3 % (cola derecha: la regla es aproximada).

A4 · Cuantiles, cuartiles y rango intercuartílico

Cuantil de orden p

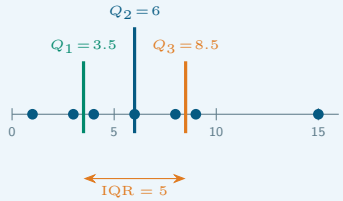
Con los datos ordenados $x_{(1)} \le \cdots \le x_{(n)}$, el cuantil q_p $(0 < p < 1)$ es el valor que deja a la izquierda una fracción p de los datos. Con interpolación lineal (lo que hacen NumPy y pandas):

$$h = (n-1)\,p+1, \qquad q_p = x_{(\lfloor h \rfloor)} + (h - \lfloor h \rfloor)\big(x_{(\lfloor h \rfloor+1)} - x_{(\lfloor h \rfloor)}\big)$$

- **Cuartiles**: $Q_1 = q_{0.25}$, $Q_2 = q_{0.50}$ (la **mediana**), $Q_3 = q_{0.75}$.
- **Percentil** k: $q_{k/100}$.
- **Rango intercuartílico**: $\mathrm{IQR} = Q_3 - Q_1$, el ancho del 50 % central.

Ejemplo con $n = 7$

$x = (1,\ 3,\ 4,\ 6,\ 8,\ 9,\ 15)$

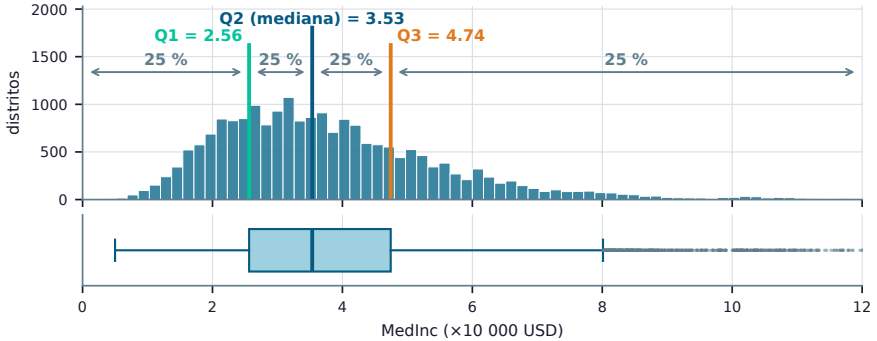


Q_1: $h = 6(0.25) + 1 = 2.5 \Rightarrow 3 + 0.5(4 - 3) = 3.5$
Q_3: $h = 6(0.75) + 1 = 5.5 \Rightarrow 8 + 0.5(9 - 8) = 8.5$

Resumen de cinco números

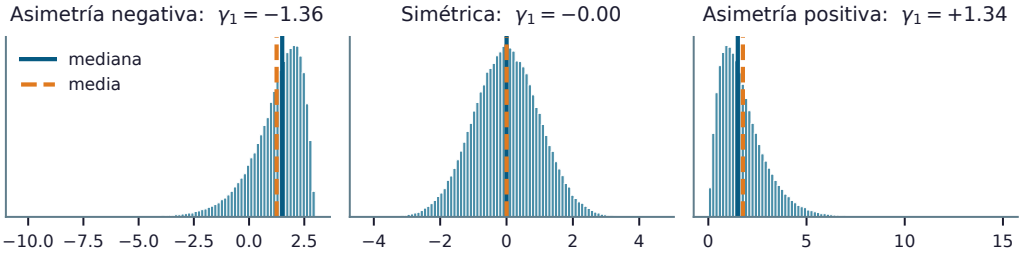
mín, Q_1, mediana, Q_3, máx
`MedInc`: 0.50, 2.56, 3.53, 4.74, 15.00 $\Rightarrow \mathrm{IQR} = 2.18$

A5 · Cómo leer cuartiles en el histograma y en el boxplot



- **Arriba** (histograma): altura = número de distritos. Las líneas Q_1, Q_2, Q_3 cortan los datos en **cuatro partes de 25 %**.
- **Abajo** (boxplot): la caja va de Q_1 a Q_3 (su ancho es el IQR) y la línea interior es la mediana.
- Misma fracción, distinto ancho: Q_1–Q_2 mide 0.97, Q_2–Q_3 mide 1.21 y el 25 % final se estira hasta 15.0. **Donde los tramos son angostos hay más datos**.
- Cola derecha larga y caja a la izquierda $\Rightarrow$ asimetría positiva.

A6 · Asimetría: hacia dónde se estira la cola



Coeficiente de asimetría

$$\gamma_1 = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{x_i - \bar{x}}{s}\right)^3$$

- $\gamma_1 > 0$: cola derecha (media $>$ mediana); $\gamma_1 < 0$: cola izquierda; $\gamma_1 \approx 0$: simétrica.
- Guía práctica: $|\gamma_1| < 0.5$ casi simétrica; > 1 fuerte.
- California: `MedInc` 1.65; `Latitude` 0.47; `HouseAge` 0.06.

A7 · Asimetría y curtosis son promedios de potencias de z

Dos ingredientes

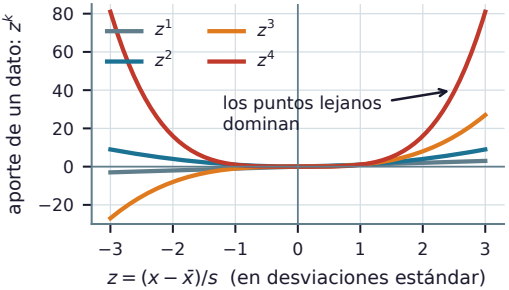
Desviación (con signo): $d_i = x_i - \bar{x}$

Puntaje z: $z_i = d_i / s$ (la misma distancia, medida en desviaciones estándar)

Promediamos la potencia k de los puntajes:

$$m_k = \frac{1}{n} \sum_{i=1}^{n} z_i^{\,k}$$

k	se llama	qué mide
2	varianza	tamaño de las desviaciones ($m_2 = 1$ por construcción)
3	asimetría γ_1	*dirección* de la cola (conserva el signo)
4	curtosis κ	peso de las colas (siempre positiva)



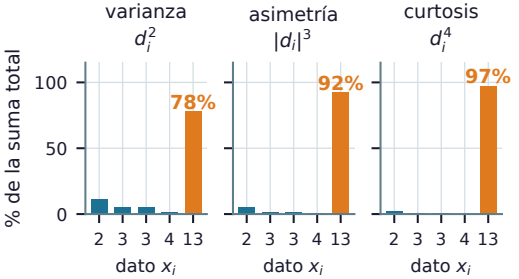
Cada dato aporta z^k a la suma. Un dato a $z = 3$ aporta 3, 9, 27 y 81 para $k = 1, \ldots, 4$. Al subir la potencia, los datos lejanos pesan cada vez más y los cercanos ($|z| < 1$) casi no cuentan.

A8 · Un solo dato lejano puede dominar la suma

Datos: $x = (2, 3, 3, 4, 13)$, con $\bar{x} = 5$ y $d_i = x_i - \bar{x}$.

	2	3	3	4	**13**	suma
d_i	-3	-2	-2	-1	**8**	0
d_i^2	9	4	4	1	**64**	82
$\lvert d_i\rvert^3$	27	8	8	1	**512**	556
d_i^4	81	16	16	1	**4096**	4210

El 13 aporta $\frac{64}{82} = \mathbf{78}\,\%$ de la suma de d^2, $\frac{512}{556} = \mathbf{92}\,\%$ de $|d|^3$ y $\frac{4096}{4210} = \mathbf{97}\,\%$ de d^4.

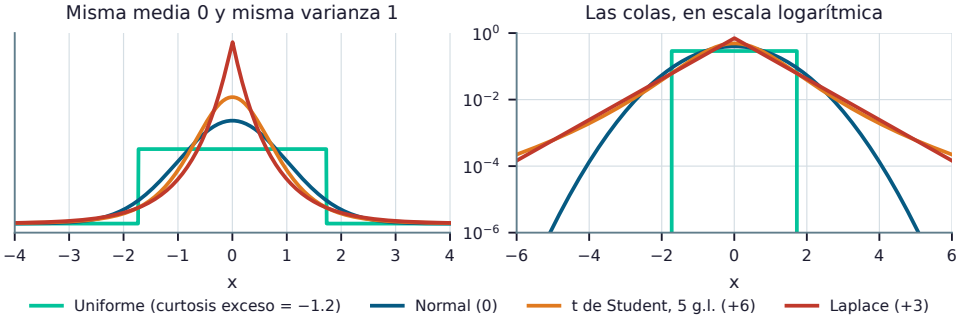


Cada barra: qué porcentaje de la suma total aporta ese dato.

Consecuencia

Con un solo dato extremo, γ_1 y κ casi dependen únicamente de él (aquí $\sum d^3 = 468 > 0$ y $\gamma_1 > 0$): **antes de interpretarlos, revisa los atípicos**, que es el tema de la sección B.

A9 · Curtosis: el peso de las colas

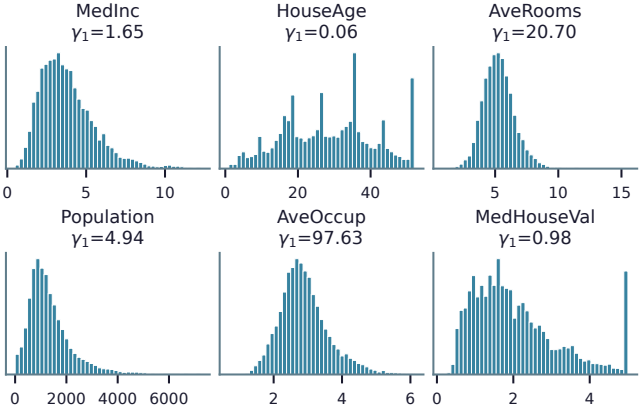


Curtosis y curtosis en exceso

$$\kappa = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{x_i - \bar{x}}{s}\right)^4, \qquad \kappa - 3$$

- La normal tiene $\kappa = 3$ (exceso 0). Exceso > 0: **colas pesadas** (más extremos).
- No es "qué tan puntiaguda": es *cuántos valores extremos* hay para la misma varianza.

A10 · Seis variables, seis formas



Se omite el 0.5 % superior para poder ver la forma.

- `MedInc`: cola derecha larga
- `HouseAge`: casi uniforme, con una **barra extra en 52**
- `AveRooms`: concentrada, con valores extremos
- `Population`: muy asimétrica
- `AveOccup`: casi todo cerca de 3
- `MedHouseVal`: asimétrica, con **pico en 5.0**

Los picos en 52 y 5.0 son una pista: los vemos en B.

A11 · El resumen numérico de California Housing

Variable	media	mediana	desv. est.	γ_1	curt. exceso	mín	máx
`MedInc`	3.87	3.53	1.90	1.65	4.95	0.50	15.00
`HouseAge`	28.64	29.0	12.59	0.06	-0.80	1	52
`AveRooms`	5.43	5.23	2.47	20.7	879	0.85	141.9
`AveBedrms`	1.10	1.05	0.47	≈ 31	$\approx 1\,600$	0.33	34.1
`Population`	1 425	1 166	1 132	4.94	73.6	3	35 682
`AveOccup`	3.07	2.82	10.39	97.6	10 651	0.69	1 243
`Latitude`	35.63	34.26	2.14	0.47	-1.12	32.54	41.95
`Longitude`	-119.57	-118.49	2.00	-0.30	-1.33	-124.35	-114.31
`MedHouseVal`	2.07	1.80	1.15	0.98	0.33	0.15	5.00

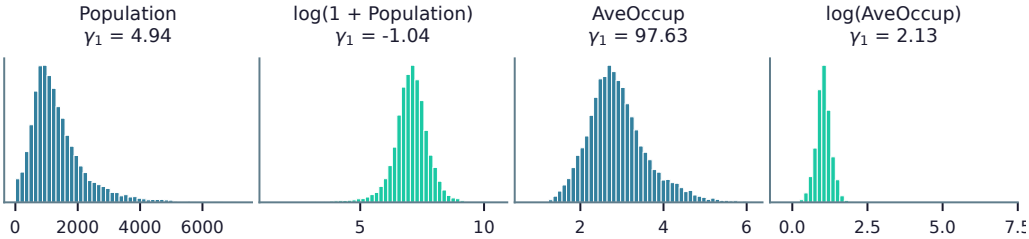
Lectura

- `AveOccup`: media 3.07 pero máximo 1 243 y $\gamma_1 \approx 98$: hay datos *fuera de escala*.
- `Latitude`/`Longitude`: exceso < 0 (dos zonas pobladas, sin colas).

Regla rápida

Si media y mediana difieren mucho, o $|\gamma_1|$ y $\kappa - 3$ son enormes, **investiga antes de modelar**. (Valores de pandas; `AveBedrms` aproximado.)

A12 · Transformar para domar colas: el logaritmo



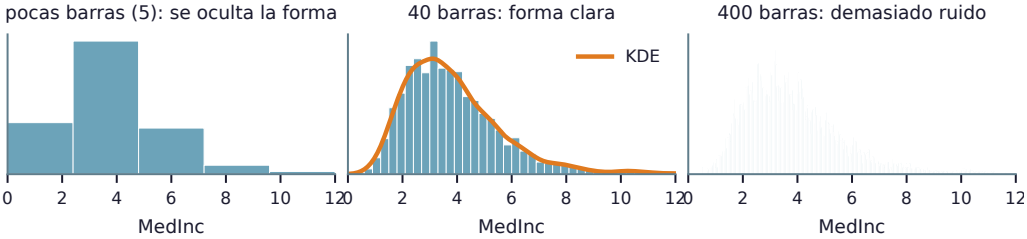
Idea

$y = \log(1 + x)$ (o $\log x$ si $x > 0$): comprime lo grande, estira lo chico; multiplicar $\rightarrow$ sumar.

- `Population`: γ_1 pasa de 4.94 a -1.04 (casi simétrica, algo corregida de más).
- `AveOccup`: de 97.6 a 2.13: mejora mucho, pero los extremos siguen ahí.

Pausa: media 10 y mediana 6, ¿qué forma esperas y qué signo tendrá γ_1?

B1 · Histogramas: el número de barras importa



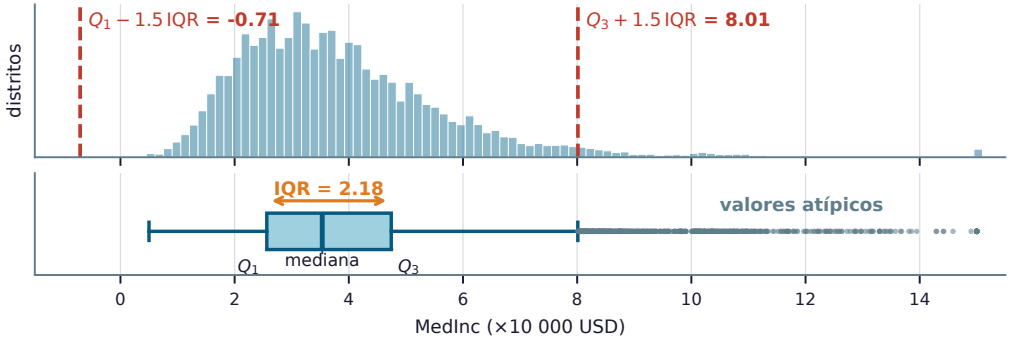
- El **área** de cada barra es proporcional a la fracción de datos en ese intervalo.
- Pocas barras ocultan la forma; demasiadas dibujan ruido.
- Regla de Freedman–Diaconis: ancho $h = 2\,\mathrm{IQR}\,n^{-1/3}$ (≈ 0.16 para `MedInc`).

KDE: histograma suavizado

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - x_i}{h}\right)$$

Una campanita K sobre cada dato; h controla el suavizado.

B2 · Boxplot y la regla $1.5 \cdot \mathrm{IQR}$



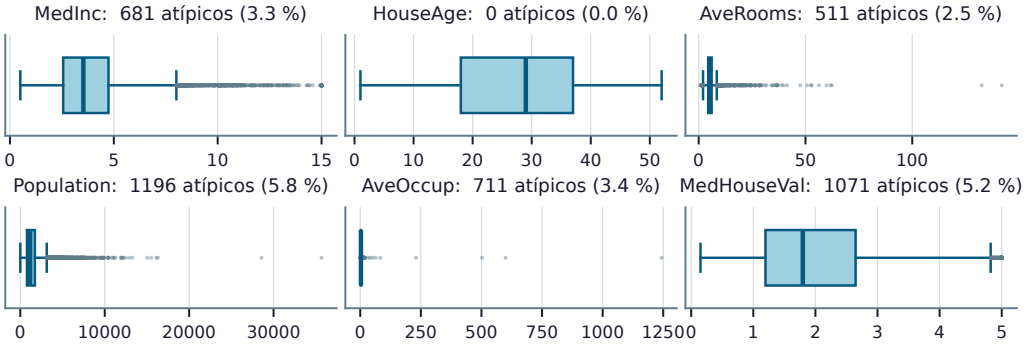
Cercas de Tukey

$$[\,Q_1 - 1.5\,\mathrm{IQR},\;\; Q_3 + 1.5\,\mathrm{IQR}\,] = [-0.71,\; 8.01]$$

La caja = 50 % central; los bigotes llegan al dato más extremo *dentro* de las cercas; lo de fuera son **atípicos**: 681 distritos (3.3 %).

¿Por qué 1.5? En una normal, las cercas quedan en $\pm 2.7\sigma$ y marcan $\approx 0.7\,\%$ de los datos.

B3 · Contar atípicos con la regla del IQR

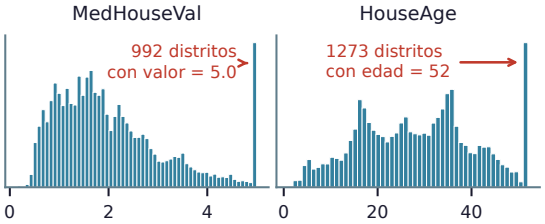


- Variables asimétricas marcan muchos puntos en la cola larga (`Population`: 5.8 %).
- `HouseAge`: 0 atípicos, pero con un pico en el tope.

Cuidado

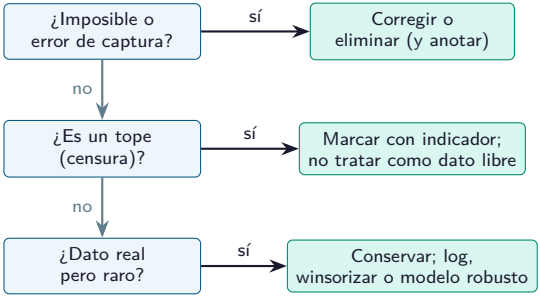
El IQR marca lo *inusual*, no lo *incorrecto*: "atípico" no significa "error".

B4 · Un atípico, ¿qué hago con él?



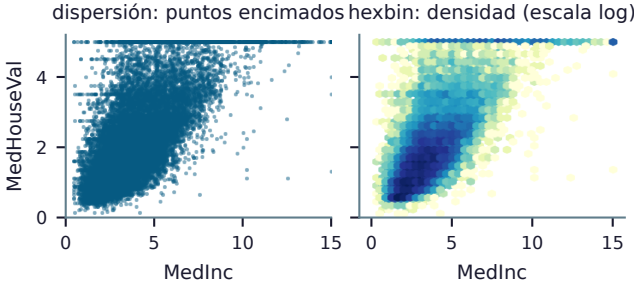
Qué encontramos

- 992 distritos con `MedHouseVal` $= 5.0$ y 1 273 con `HouseAge` $= 52$: **topes** (valores truncados).
- `AveRooms` hasta 141.9 con 30 habitantes; `AveOccup` hasta 1 243: casi seguro **casos raros o errores**.



Siempre: documenta la decisión

C1 · Dos variables numéricas: dispersión y hexbin

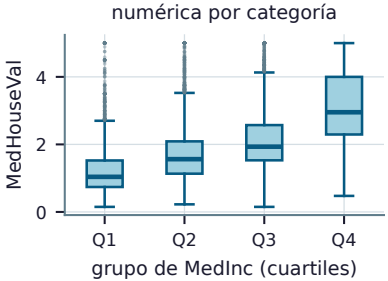


Izquierda: con $n = 20\,640$ los puntos se superponen (*overplotting*) y solo se ve una mancha.
Derecha: el *hexbin* cuenta los puntos que caen en cada celda hexagonal; **color más oscuro = más distritos** (escala logarítmica).

Qué mirar en una dispersión

1. **Dirección**: ¿sube (asociación positiva) o baja (negativa)? Aquí sube: más ingreso, mayor valor de la vivienda.
2. **Forma**: ¿recta, curva, varios grupos?
3. **Fuerza**: qué tan angosta es la nube alrededor de la tendencia.
4. **Excepciones**: puntos aislados y la fila horizontal en `MedHouseVal` $= 5$ (el tope de la sección B).

C2 · Una numérica contra una categórica: boxplots por grupo



Cómo se construye

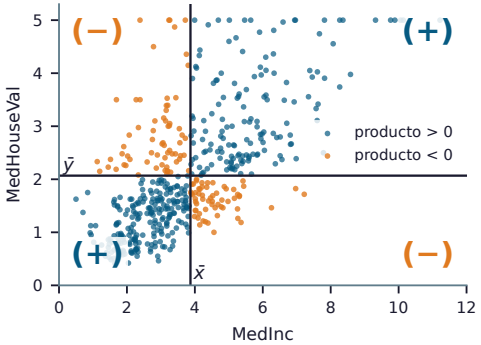
Cortamos `MedInc` en 4 grupos con sus cuartiles (Q_1: 0.50–2.56, Q_2: 2.56–3.53, Q_3: 3.53–4.74, Q_4: 4.74–15.0), cada uno con 5 160 distritos, y dibujamos un boxplot de `MedHouseVal` por grupo.

Cómo se lee

- **Medianas** (línea de cada caja): 1.04, 1.56, 1.93 y 2.95 $\Rightarrow$ crecen con el ingreso.
- **Cajas**: el IQR crece de 0.79 a 1.71; con ingreso alto el precio varía más.
- **Puntos de arriba**: valores altos, hasta el tope 5.0.

Par de variables	Gráfica	Resumen
num.–num.	dispersión / hexbin	s_{xy}, r, ρ_s
num.–cat.	boxplot por grupo	mediana e IQR por grupo
cat.–cat.	tabla de contingencia / barras apiladas	conteos y proporciones

C3 · Covarianza paso a paso



Azul: producto > 0 (75 % de los puntos de la muestra). Naranja: producto < 0.

1. Calcula las medias $\bar{x}$ y $\bar{y}$ (las dos líneas negras).

2. Para cada dato, $d_x = x_i - \bar{x}$ y $d_y = y_i - \bar{y}$: en qué lado de cada línea está.

3. Multiplica $d_x\, d_y$; el signo depende del cuadrante:

cuadrante	d_x	d_y	$d_x d_y$
arriba-derecha	$+$	$+$	$+$
abajo-izquierda	$-$	$-$	$+$
arriba-izquierda	$-$	$+$	$-$
abajo-derecha	$+$	$-$	$-$

4. Promedia (con $n-1$):

$$s_{xy} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})$$

C4 · Qué significa la covarianza y por qué no basta

Cómo interpretar su signo

- $s_{xy} > 0$: tienden a subir juntas (domina el $+$).
- $s_{xy} < 0$: cuando una sube, la otra tiende a bajar.
- $s_{xy} \approx 0$: no hay tendencia *lineal* (los $+$ y $-$ se compensan).
- Con $y = x$: $s_{xx} = s_x^2$, la varianza es un caso especial.

Una cota

$|s_{xy}| \leq s_x\, s_y$ (Cauchy–Schwarz). Por eso el cociente $s_{xy}/(s_x s_y)$ queda entre -1 y 1.

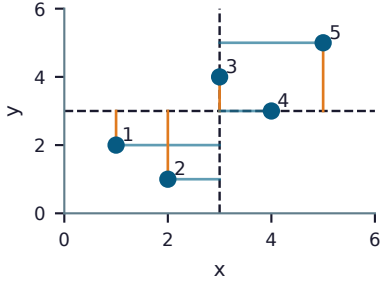
El tamaño depende de las unidades

`MedInc` contra `MedHouseVal`, *la misma relación* medida en dos unidades:

unidades	s_{xy}	$s_x s_y$	$s_{xy}/(s_x s_y)$
10^4 USD y 10^5 USD	1.51	2.19	**0.69**
USD y USD	1.51×10^9	2.19×10^9	**0.69**

s_{xy} se multiplicó por 10^9 sin que cambiara la relación: no sabemos si 1.51 es "mucho". Al dividir entre $s_x s_y$ las unidades se cancelan.

C5 · Correlación de Pearson: estandarizar la covarianza



Cinco puntos. Rectas punteadas: $\bar{x} = \bar{y} = 3$.

Segmentos horizontales: d_x; verticales (naranja): d_y.

Definición

$$r = \frac{s_{xy}}{s_x\, s_y} = \frac{1}{n-1} \sum_{i=1}^{n} z_{x_i}\, z_{y_i}$$

Dividir entre $s_x s_y$ equivale a convertir cada variable a puntajes z (media 0, desv. est. 1) y promediar los productos.

Con $x = (1, 2, 3, 4, 5)$ y $y = (2, 1, 4, 3, 5)$:

- $\sum d_x d_y = (-2)(-1) + (-1)(-2) + 0 \cdot 1 + 1 \cdot 0 + 2 \cdot 2 = 8$, $s_{xy} = 8/4 = 2$
- $s_x^2 = s_y^2 = \frac{4+1+0+1+4}{4} = 2.5, \quad s_x s_y = 2.5$
- $r = 2/2.5 = \mathbf{0.80}$

C6 · Calcular r con puntajes z y cómo leerla

i	x	y	z_x	z_y	$z_x z_y$
1	1	2	-1.26	-0.63	0.80
2	2	1	-0.63	-1.26	0.80
3	3	4	0	0.63	0
4	4	3	0.63	0	0
5	5	5	1.26	1.26	1.60
				suma $= 3.20$	$r = 3.20/4 = \mathbf{0.80}$

$z_x = (x - 3)/1.58$. Si los dos z tienen el mismo signo, el producto es positivo.

Otra lectura: si $u = (d_{x_1}, \ldots, d_{x_n})$ y $v = (d_{y_1}, \ldots, d_{y_n})$ son los vectores de desviaciones, entonces $r = \cos\theta$ con θ el ángulo entre u y v: $r = 1$ (misma dirección), $r = 0$ (perpendiculares), $r = -1$ (opuestas).

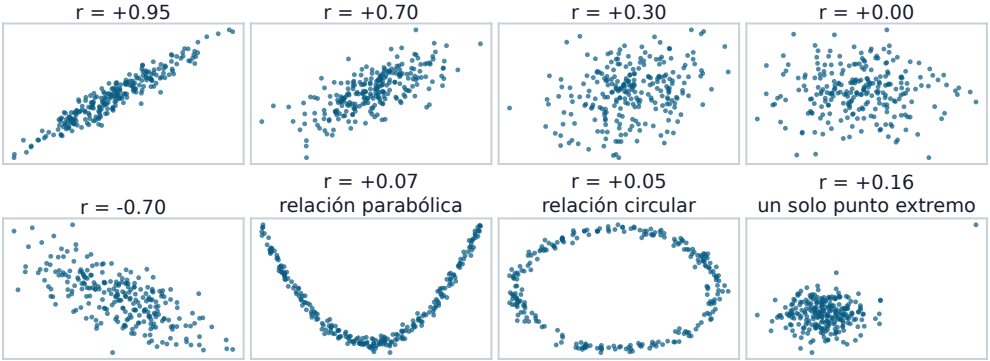
Cómo leer r

- $-1 \leq r \leq 1$; el signo da la dirección y $|r|$ la *fuerza lineal*.
- No cambia si cambias las unidades ni si sumas constantes.
- $|r| = 1$ solo si los puntos están exactamente sobre una recta.
- r^2 = fracción de la varianza de y que explica la recta de ajuste.

California

`MedInc`–`MedHouseVal`: $r = 0.69$, así que $r^2 = 0.47$: el ingreso "explica" cerca de la mitad de la variación del precio. Orientativo: $|r| < 0.3$ débil, 0.3–0.7 moderada, > 0.7 fuerte.

C7 · ¿Qué puede (y qué no) decir r?



- r mide solo la parte **lineal**.
- Parabóla y círculo: relación perfecta con $r \approx 0$.

Un solo dato basta

Un punto extremo hace pasar r de 0 a 0.16 en la última gráfica.

C8 · Spearman (1/2): la idea de usar rangos

Por qué hace falta

Pearson usa los **valores** y por eso un solo dato enorme puede dominar la suma $\sum d_x d_y$. Spearman conserva solo el **orden**: "quién es el mayor, el segundo…", sin importar *cuánto* mayor.

Procedimiento

1. Ordena x de menor a mayor y reemplaza cada valor por su **rango**: $1 =$ el menor, $n =$ el mayor. Haz lo mismo con y.
2. **Empates**: si varios valores son iguales, cada uno recibe el promedio de los rangos que ocuparían, p. ej. $(10, 20, 20, 40) \mapsto (1,\ 2.5,\ 2.5,\ 4)$.
3. Calcula la correlación de Pearson entre los rangos:

$$\rho_s = r\Big(\text{rango}(x), \text{rango}(y)\Big)$$

Ejemplo con un dato extremo

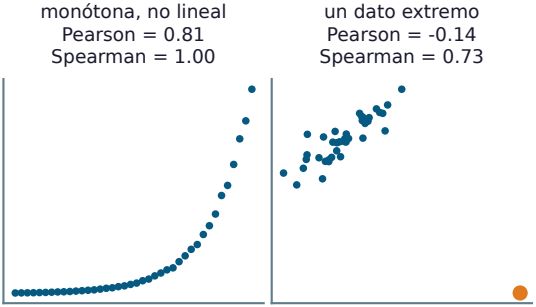
	$i=1$	2	3	4	5
x	1	2	3	4	5
y	2	3	5	9	**90**
rango(x)	1	2	3	4	5
rango(y)	1	2	3	4	**5**

- El 90 pasa a ser simplemente "el quinto": ya no pesa 90 sino 5.
- Los rangos de x y de y coinciden, así que $\rho_s = \mathbf{1.00}$: *cada vez que x sube, y sube.*
- Pearson con los valores originales: $r = 0.75$, porque el 90 domina.

Atajo sin empates

$\rho_s = 1 - \dfrac{6\sum_i \Delta_i^2}{n(n^2-1)}$, con $\Delta_i = \text{rango}(x_i) - \text{rango}(y_i)$. Aquí todos los $\Delta_i = 0$, así que $\rho_s = 1$.

C9 · Spearman (2/2): cuándo usarla



Izquierda: relación siempre creciente pero curva; Pearson solo ve la parte lineal (0.81), Spearman ve que es perfectamente monótona (1.00).
Derecha: una nube con tendencia positiva y un solo dato extremo (naranja). Pearson cae a -0.14; Spearman marca 0.73, que sí describe a la nube.

Qué mide cada una

- **Pearson**: qué tan bien se ajusta una *recta*.
- **Spearman**: qué tan bien se ajusta una relación que *siempre sube* (o siempre baja), de la forma que sea.

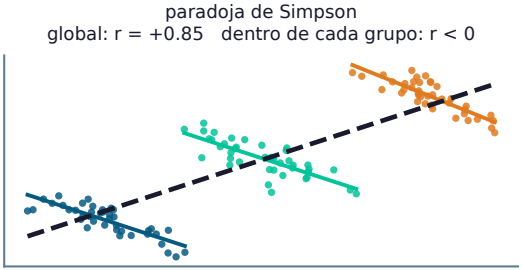
Cuándo preferirla

- Hay atípicos o colas pesadas.
- La relación es curva pero monótona.
- Las variables son ordinales (escalas 1–5, rangos).

California

`MedInc`–`MedHouseVal`: $r = 0.69$, $\rho_s = 0.68$ (coinciden: relación casi lineal).
`AveOccup`–`MedHouseVal`: $r = -0.02$ pero $\rho_s = -0.26$: los extremos escondían la relación.

C10 · La paradoja de Simpson: cuidado con los subgrupos



Qué muestra la figura

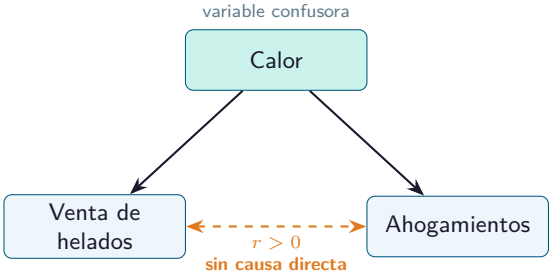
Tres grupos (colores). **Dentro de cada grupo**, al subir x baja y ($r < 0$). Pero los grupos con x alto también tienen y alto de base, y al juntarlos la recta global (negra, discontinua) **sube**: $r = +0.85$.

Ejemplo: x = dosis de un medicamento, y = presión arterial, grupos = rangos de edad. En cada edad, más dosis baja la presión; pero los mayores reciben dosis más altas y parten de presión más alta.

Qué hacer

Cuando haya una variable de grupo, **colorea por grupo** y calcula r *dentro* de cada uno. Un solo r global puede decir lo contrario de lo que pasa en cada subgrupo.

C11 · Correlación no es causalidad



Si X y Y están correlacionadas, puede ser que:

1. X cause Y,
2. Y cause X,
3. una tercera variable Z cause ambas, o
4. sea coincidencia.

En California

¿`MedInc` causa `MedHouseVal`? Quizá la *ubicación* (costa) influye en ambas. Para predecir basta la asociación; para *explicar*, no.

D1 · La matriz de correlación: todos los pares a la vez

$$R = \frac{1}{n-1}\underbrace{Z^\top}_{p\times n}\underbrace{Z}_{n\times p} = \underbrace{R}_{p\times p}$$

$$Z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

cada columna está estandarizada

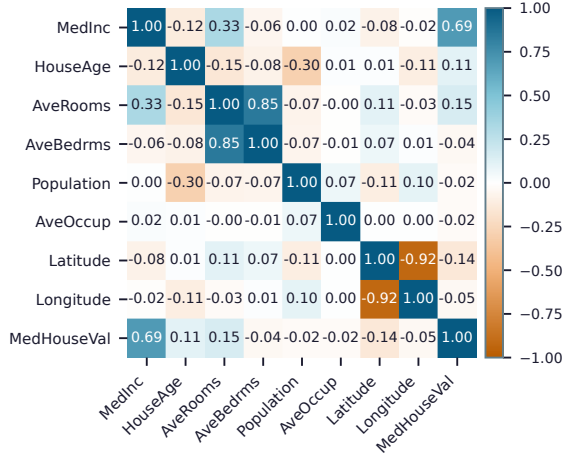
Propiedades

- $R_{ii} = 1$ (cada variable consigo misma)
- $R_{ij} = R_{ji}$: simétrica
- $-1 \le R_{ij} \le 1$, con $R_{ij} = r(\text{var}_i, \text{var}_j)$

Para California

$p = 9$ variables $\Rightarrow \binom{9}{2} = 36$ pares distintos: demasiados para mirar uno por uno. La **matriz** los resume; el **heatmap** los colorea.

D2 · El heatmap de California Housing



Cómo leerlo

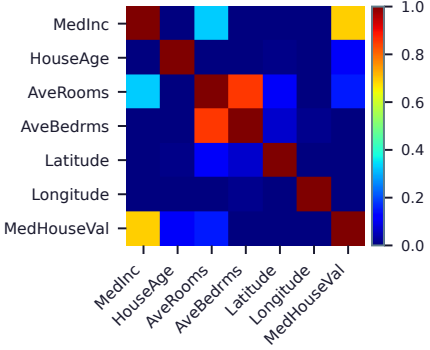
- `MedInc`–`MedHouseVal`: $\mathbf{0.69}$, la más fuerte con el objetivo.
- `Latitude`–`Longitude`: -0.92 (la costa corre en diagonal).
- `AveRooms`–`AveBedrms`: $0.85\ldots$ pero Spearman ≈ 0.10 (¡sospechoso!).
- `HouseAge`–`Population`: -0.30.

Sospecha

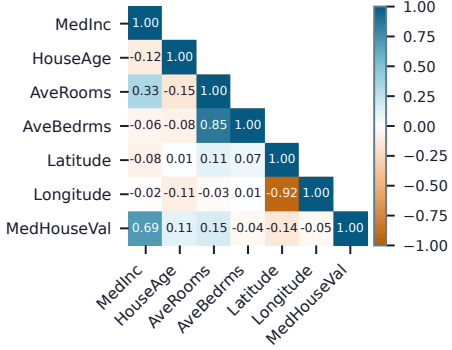
`AveOccup`: $r = -0.02$ pero Spearman $= -0.26$. Los extremos pueden *aplastar* (o *inflar*) a r: revisa los atípicos antes de concluir.

D3 · Un heatmap que se deja leer

Evitar: escala arco iris, sin centro en 0, matriz repetida

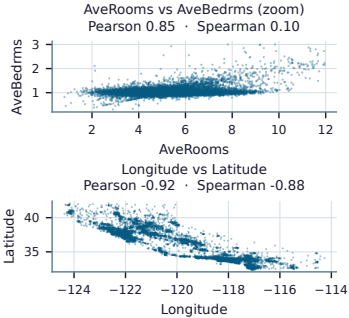


Preferir: escala divergente centrada en 0, triángulo inferior, valores anotados

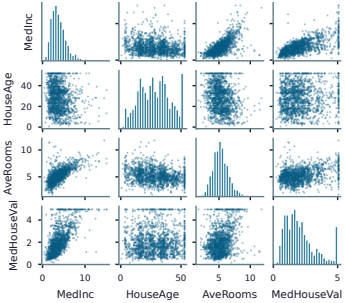


Escala divergente centrada en 0 · **solo el triángulo inferior** · **valores anotados** · evitar “arco iris”

D4 · Multicolinealidad y matriz de dispersión



`AveRooms`–`AveBedrms`: $r = 0.85$ pero $\rho_s = 0.10$; sin el 1.3 % más extremo, $r \approx 0.2$. `Lon`–`Lat`: colinealidad *real*.



Matriz de dispersión: diagonal = histograma; fuera de ella, los pares.

Consecuencia

Con predictores muy correlacionados, la regresión lineal se vuelve inestable. El *VIF* lo mide: $\mathrm{VIF}_j = 1/(1 - R_j^2)$, con R_j^2 lo que las demás variables explican de la j-ésima. **Antes de culpar a la colinealidad, revisa si la crean unos pocos atípicos.**

Receta de EDA en seis pasos

Receta

1. **Forma**: tamaño, tipos, faltantes.
2. **Resumen**: $\bar{x}$, mediana, s, γ_1, $\kappa - 3$.
3. **Gráficas** univariadas: histograma y boxplot.
4. **Atípicos y topes**: regla IQR, y *decidir*.
5. **Pares**: dispersión, r/ρ_s, heatmap.
6. **Documentar** cada decisión.

Trampas frecuentes

- Confiar solo en resúmenes (Anscombe)
- Borrar atípicos sin pensar
- Ignorar topes (5.0 y 52)
- Leer r como causalidad
- **Fugas**: calcular estadísticos con *todos* los datos

Conexión con la sesión 1: las decisiones del EDA (cercas, medias, transformaciones) se ajustan con el conjunto de *entrenamiento*.

Del concepto al código

```python
from sklearn.datasets import fetch_california_housing
df = fetch_california_housing(as_frame=True).frame

df.describe()                       # n, media, std, cuartiles, min, max
df.skew(); df.kurt()                # asimetria y curtosis (en exceso)

q1, q3 = df["MedInc"].quantile([.25, .75])
iqr = q3 - q1
mask = (df["MedInc"] < q1 - 1.5*iqr) | (df["MedInc"] > q3 + 1.5*iqr)
mask.sum()                          # numero de atipicos

C = df.corr()                       # matriz de correlacion (Pearson)
plt.imshow(C, cmap="RdBu", vmin=-1, vmax=1); plt.colorbar()
```

Actividad: EDA de California Housing

Notebook: `actividad_unidad1_eda_california_housing`

1. Cargar los datos y obtener el resumen numérico
2. Histogramas y boxplots de las variables
3. Contar atípicos con la regla del IQR
4. Inspeccionar filas extremas y los topes (5.0, 52)
5. **Decidir** el tratamiento de cada variable
6. Matriz de correlación y heatmap; multicolinealidad

Entregable

Una tabla por variable:

% atípicos | **decisión** | **justificación**

Formato: individual. Al terminar, sube el notebook ejecutado y la tabla.

Tiempo: lo que quede de sesión.



¿Preguntas?

¡Pasemos a la actividad con California Housing!
